

CORSO DI LAUREA MAGISTRALE INGEGNERIA ELETTRONICA
SECONDO ANNO

DE LUCA ANDREA MATRICOLA NR. 252417

LOW POWER

ENERGY-DELAY OPTIMIZATION FOR A THREE-STAGES CMOS
BUFFER

ANNO 2024/25


INTRODUZIONE

Il seguente progetto ha come obiettivo quello di **ottimizzare** il design di un **circuito combinatorio** tramite la **sensitivity analysis**, che viene fatta sul piano **energia-ritardo**, variando due parametri riguardanti il dimensionamento del circuito tramite una simulazione **montecarlo**.

Questo procedimento porterà all'estrazione di una **nuvola di punti** nel piano **Energy-Delay**, definibile come una curva empirica, che si troverà per i valori più bassi a coincidere quasi perfettamente con la curva di ottimo di Pareto. Una volta trovati i punti di design, per ogni valore di ritardo si cercherà di trovare il valore minimo di energia tramite l'analisi sopra citata, che viene fatta tramite un tool di ottimizzazione numerica, il quale andrà a variare i due parametri finché non avrà ottenuto quelli per cui si ricava il valore di energia più vicino a quello corrispondente della curva di ottimo. Dopodiché verranno confrontate le due curve per controllare che la curva empirica sia situata sopra la curva di ottimo.

In un **circuito digitale combinatorio** bisogna sempre trovare un **compromesso** tra **energia dissipata e velocità di calcolo**, la quale può essere misurata tramite il **ritardo**. Ognuno di questi valori può essere modificato andando ad agire su delle variabili indipendenti, che possono essere i **parametri geometrici** dei **transistor** (lunghezza **L** e larghezza **W** dei MOSFET) o la **tensione di alimentazione V_{dd}** . Sappiamo che un **circuito digitale** dissipa un'energia dinamica pari a $C * V_{dd}^2$, dove **C** dipende dalle **dimensioni** dei transistor.

1 ANALISI DEL BUFFER A TRE STADI



La struttura presa in esame è il **buffer a tre stadi** mostrato in figura. Per questo **circuito** sono stati imposti degli specifici **vincoli di progettazione**:

- Il **primo inverter** presenta un **dimensionamento minimo**
- La **capacità di carico** è modellata dall'inserimento di un ulteriore **inverter 50 volte più grande** dell'inverter minimo
- I **parametri** che si possono far variare per l'analisi di sensitività sono **W1** e **W2**, variabili relative al dimensionamento degli inverter. Nello specifico **W1** indica il

- **rapporto d'aspetto del secondo inverter** rispetto alle dimensioni del primo e **W2** il **rapporto d'aspetto del terzo inverter** sempre rispetto alle dimensioni del primo
- La **lunghezza di canale L** è la medesima per tutti i **transistor** del circuito.

Per questa struttura si vuole risolvere il seguente **problema di ottimizzazione vincolata** formulato nel seguente modo:


$$\begin{cases} \min E(W1, W2) \\ D(W1, W2) = D0 \end{cases}$$

Variando i parametri **W1** e **W2** del circuito si vuole trovare per ciascun **ritardo fissato** $D(W1, W2) = D0$ il **valore minimo di energia** $E(W1, W2)$. Per risolvere questo problema, in primo luogo, sarà opportuno progettare il **primo inverter** in modo che abbia un **dimensionamento minimo**; successivamente servirà formulare i **modelli** che descrivono $D(W1, W2)$ ed $E(W1, W2)$, realizzati tramite l'estrazione di specifici **parametri di fitting**.

Dopodiché si procederà ad eseguire una **simulazione montecarlo** per ottenere la **curva empirica** che verrà confrontata poi con una **curva teorica** calcolata tramite la **sensitivity analysis**, secondo la quale il **valore di energia minore** si ottiene variando le **variabili indipendenti**, nel nostro caso **W1** e **W2**. La **curva teorica** pertanto sarà data dai **valori minori di energia** ottenuti per degli **specifici ritardi**, scelti in base al range ottenuto tramite la **simulazione montecarlo**.

2 DIMENSIONAMENTO DELL'INVERTER MINIMO

Il primo passo da fare è dimensionare il primo inverter in modo che abbia un **dimensionamento minimo**. Un inverter si dice **dimensionato al minimo** se il suo **ritardo di salita** e il suo **ritardo di discesa** sono pressoché uguali. Per valutare sperimentalmente il dimensionamento appropriato è stato simulato un **inverter** dove l'**NMOS** ha una larghezza di canale **Wn** fissata a **0,12 μm**.




Partendo da questo vincolo si varia la larghezza di canale del **PMOS** per trovare il valore che soddisfa il criterio.

Nella simulazione in **transitorio** della durata di **50 ns**. **Wp** viene fatta variare da **0,12 μm** a **0,36 μm** con un passo di **0,01 μm** tramite la direttiva "**step param**"; in seguito per ogni valore di **W** si calcolano i **tempi di salita** e **discesa** tramite le seguenti espressioni contenute nel file "**Delay_script.txt**".

```
.measure tran ritardo_rise trig v(in) val=0.5 fall=1 targ v(Out) val=0.5 rise=1
.measure tran ritardo_fall trig v(in) val=0.5 rise=1 targ v(Out) val=0.5 fall=1
```

I risultati sono stati confrontati su excel ed è stato osservato che i due ritardi sono più simili quando **Wp=0.2 μm** .



3 ESTRAZIONE DEI MODELLI DI ENERGIA E RITARDO

Una volta dimensionato il **primo inverter**, è stato necessario ricavare i **modelli** che descrivono l'andamento di **energia e ritardo** in funzione delle due **variabili di sizing W1 e W2**. Per ottenerli sono stati calcolati degli opportuni **parametri di fitting**.

3.1 Parametri di fitting per il modello dell'energia

Sappiamo che per un **inverter CMOS** l'**energia dissipata** è data dal prodotto tra la **capacità** vista in uscita dall'inverter e il quadrato della **Vdd**. Per ogni inverter la **capacità totale** è data da $C_{in} + C_d + C_w$, dove C_w è la **capacità del metallo** che connette il circuito al carico, C_d è la **capacità parassita vista sul drain** e C_{in} è la **capacità d'ingresso**. Nel seguente progetto la **capacità del metallo** si considera trascurabile. Per il **primo inverter**, siccome è dimensionato al minimo, si considera una **capacità d'ingresso minima C_{min}** . Per ciascuno


degli inverter la **capacità d'ingresso** è funzione del **sizing** dei dispositivi, quindi per il primo inverter $C_{in} = C_{min}$, per il secondo $C_{in} = C_{min} * W1$ e per il terzo $C_{in} = C_{min} * W2$.

Si definisce γ_E il rapporto tra **capacità di uscita** (C_{dmin}) e **capacità di ingresso** C_{min} del primo inverter. Con questo parametro possiamo affermare che la **capacità di uscita** è pari a $\gamma_E * C_{min}$ e ottenere la seguente espressione dell'energia dissipata dal buffer:

$$E = Vdd^2 * (\gamma_E * C_{min} + W1 * C_{min} + \gamma_E * C_{min} * W1 + W2 * C_{min} + \gamma_E * C_{min} * W2)$$


Si osserva come i parametri di fitting da ricavare sono γ_E e C_{min} .

Per ottenere C_{min} è stato necessario ricavare prima C_{dmin} . Per farlo su **LTSpice** è stato simulato un **inverter minimo** che presenta un carico capacitivo C_l , il quale è stato fatto variare da 1 fF a 10 fF con step di 1 fF.



Questo circuito consuma un'energia $|E| = Vdd^2 * (C_d + C_l)$, da cui $C_d = \frac{|E|}{Vdd^2} - C_l$. Per ogni valore di C_l tramite il file "**Delay script.txt**" è stata calcolata l'**energia dell'inverter**, pari al prodotto tra l'**integrale della corrente del generatore V2** e la **tensione Vdd**. Dopodiché su un file excel è stata implementata la formula per calcolare C_d , la quale nel caso specifico risulta semplificata, dal momento che la Vdd è pari ad 1 V. Ottenuti tutti i valori di C_d , per ricavare quello minimo è stata fatta una semplice media, dalla quale si ottiene che **$C_{dmin}=0,468$ fF**.

Per ottenere C_{min} è stata fatta la stessa simulazione, ma mettendo come carico un altro **inverter minimo** e settando due differenti **tensioni di alimentazione** per entrambi gli inverter, dal momento che ci interessa solo **l'energia del primo** e utilizzando due generatori separati si ha che la **capacità di drain del primo inverter** è esattamente la **capacità minima del secondo**.



In questo caso $|E| = V_{dd}^2 * (C_{dmin} + C_{min})$. Considerando la **tensione di alimentazione** del primo inverter, otteniamo $C_{min} = |E| - C_{dmin}$: numericamente è pari a **0,903 fF**. Dal rapporto tra C_{dmin} e C_{min} è stato ricavato l'altro parametro di fitting, γ_E , pari a **0,518**.

3.2 Parametri di fitting per il modello del ritardo

Per modellare il **ritardo** viene considerata la seguente formula.

$$\tau_p = \tau_{NOM} * (1 + 1 * \frac{C_{OUT}}{\gamma_D * C_{IN}})$$

I **parametri** da ricavare sono τ_{NOM} e γ_D . Il primo rappresenta il **ritardo nominale dell'inverter a vuoto**: è stato ottenuto simulando un inverter senza carico attaccato e prendendo tra i due ritardi calcolati con il file "**Delay script.txt**" (tempo di salita e tempo di discesa) quello maggiore, pari a **11,8 ps**.


Per ricavare γ_D ci si è messi nella **condizione** in cui $C_{OUT} = C_{IN}$: è quella che si ha quando si attacca come carico un **inverter minimo**. Pertanto, è stata utilizzata la stessa **simulazione** dell'analisi precedente, ma in questo caso viene calcolato il **ritardo del primo inverter τ_p** , che si ricava come nel caso del τ_{NOM} , ed è pari a **29,7 ps**; dopodiché è stato ricavato il secondo **parametro di fitting** tramite la seguente formula:

$$\gamma_D = \frac{\tau_{NOM}}{\tau_p - \tau_{NOM}}$$

Il γ_D ottenuto è pari a 0,662.

4 ESTRAZIONE DELLA CURVA EMPIRICA TRAMITE SIMULAZIONE MONTECARLO

Una volta ottenuti i **parametri** del **modello**, come step successivo viene eseguita una **simulazione montecarlo** andando a modificare i due **parametri di sizing**. Nella figura sottostante è riportato il **setup di simulazione**.




Per far variare le due grandezze in un **intervallo ben preciso** viene utilizzato il comando **mc(x,y)** con il quale ciascun valore viene fatto variare nel **range** che va da $x^*(1+y)$ a $x^*(1-y)$: nel circuito preso in esame **w1** viene fatto variare tra **1** e **7 μm** e **w2** tra **4** e **28 μm** . Vengono scelti questi **specifici intervalli** per poter ottenere un **range di ritardi** che va da **250** a **350 ps**. Si può notare come il **buffer** e il **carico** sono stati alimentati con due **generatori differenti**, seppur erogano la **stessa tensione**: questa cosa viene fatta per impedire che **l'energia dissipata dal buffer** venga influenzata dalla **corrente sul carico**.


Per questa **analisi** sono stati simulati **10000 buffer**, il numero minimo richiesto per ottenere dei risultati sufficientemente accurati. A simulazione terminata, vengono ricavati i valori di ritardo ed energia tramite lo script **“EnergyMeas.txt”** riportato sotto in figura.

```
.measure tran energia INTEG 0.5*1*(abs(I(V2)*V(supply))-(I(V2)*V(supply))) from=3n to=13n
.measure tran ritardo fall trig v(IN) val=0.5 rise=1 targ v(n002) val=0.5 fall=1
```

Come già detto nel capitolo precedente l'**energia** si ottiene integrando la **potenza**, quindi della **corrente**, dal momento che la **tensione di alimentazione** è costante. Per spiegare come viene eseguito l'integrale si osservi l'andamento della **corrente del generatore V2**.



Si può notare come è presente un **segnale spurio** che non ci interessa misurare. Per levarlo si ricava il **valore assoluto della corrente**, poi lo si sottrae alla **corrente osservata** e dopodiché si divide per due: in questo modo consideriamo solo la **variazione di corrente** che si ha nelle transizioni **1->0** e **0->1**.



Il grafico ottenuto mostra l'involuppo dei punti di design nello spazio **Energy-Delay**.

Si osservi come variando i due **rapporti d'aspetto** per eseguire la **sensitivity analysis**, la maggior parte dei circuiti simulati tende ad avere un basso **ritardo** ed un'**energia** ridotta, mentre la tendenza meno seguita è avere un circuito con **ritardo** ed energia elevati. Il **range di ritardi** ottenuto è quello desiderato, da **250 a 350 ps**. L'approccio ha come scopo quello di ottenere le coppie di punti che danno i valori di energia più bassi per i vari ritardi.

5 SENSITIVITY ANALYSIS PER IL CALCOLO DELLA CURVA DI OTTIMO ENERGY-DELAY

Una volta ottenuta la **curva sperimentale** plottando i risultati di **energia e ritardo** su Excel, attraverso un **tool di ottimizzazione numerica**, nel caso specifico **MATLAB**, vengono ricavati alcuni punti della **curva teorica** risolvendo i due **modelli di energia e ritardo** ricavati nei capitoli precedenti.

Questi ultimi sono stati realizzati tramite due script, **Energy_model** e **DelayConstraint**.

Energy_model

```
function [E] =Energy_model(W)

GammaE=0,518;
Vdd=1;
K=0.903;
Cload=50;
E=K*Vdd*Vdd*(GammaE+(1+GammaE)*W(1)+(1+GammaE)*W(2)+Cload);
```

La variabile **K** corrisponde alla capacità minima C_{min} , la quale viene espressa in **femto Farad**, assieme alla **capacità di carico** modellata con l'inverter 50 volte più grande rispetto al primo, in modo da ottenere un valore di **energia** espresso in **femto Joule**. Nella formulazione del **modello**, **W** è il vettore contenente i **parametri W1 e W2**.

DelayConstraint

```
function[c,ceq]=DelayConstraint(W)

tau0=11.8;
GammaD=0.662;
Cload=50;
D0=250;
ceq=tau0*(1+W(1)/(GammaD)+1+W(2)/(GammaD*W(1))+1+Cload/(GammaD*W(2)))-D0;
c=1-W(1)<0;
```

Nel seguente modello i **ritardi** sono indicati in picosecondi. **Tau0** è il **ritardo nominale dell'inverter** a vuoto. Si noti come questo secondo modello non ritorna in uscita uno specifico valore di **ritardo**, bensì impone un determinato **vincolo**, ossia che il valore di **ceq**- il ritardo della struttura di buffer- sia nullo. Ciò accade se **W1** e **W2** assumono un valore per cui il **ritardo** del **buffer**, indicato dall'espressione, è pari al **ritardo fissato D0**. Oltre a questo vincolo, viene imposto che **W1** sia **maggiore di 1**: dal momento che non si può imporre in maniera diretta un **vincolo** su una **variabile dichiarata**, si agisce sulla **variabile C=1-W** che viene imposta minore di 0, ciò equivale a quanto detto sopra. Si vuole evitare qualsiasi caso in cui si vanno a **sottodimensionare** i transistor rispetto al **caso minimo**: ciò sarebbe un problema perché gli effetti di **leakage** sarebbero troppo elevati e non trascurabili. Il **vincolo** si applica su una sola **variabile** dal momento che **W2** risulta essere sempre più grande di **W1** e quindi basta garantire il **vincolo** per quest'ultimo parametro.

Ripetendo questo procedimento per ogni **ritardo fissato D0** inserito è stata ottenuta la **coppia di parametri (W1, W2)** per la quale si ottiene il **valore minimo di energia**.

Nell'estrazione della **curva ottima** è stato considerato un **intervallo di ritardi** che va da **230 a 370 ps** con un passo di **10 ps**. La coppia ottima viene calcolata con la funzione "**fmincon**"

fmincon(@Energy_model, [10;10], [], [], [], [], [], [], @DelayConstraint)

Come si può osservare prende in ingresso una **funzione “obiettivo”** (Energy_model) soggetta a dei **vincoli** (DelayConstraint) e calcola l'**incognita o le incognite** per cui la **funzione** assume il suo **valore minimo**. La ricerca dell'incognita ottima partirà da un **valore iniziale fissato**; in questo caso il modello ne ha due, racchiuse nel vettore **W**, quindi, avremo due **valori iniziali** **W1 = W2 = 10 μm**. A partire da questi due numeri verranno trovate tutte le coppie che soddisfano i vincoli del **modello del ritardo** e per ciascuna di esse verrà ottenuta l'**energia** dall'altra funzione: ottenuti tutti i possibili risultati, **fmincon** troverà il minore e restituirà la **coppia (W1, W2)** corrispondente. Considerando il range prestabilito di ritardi sono state ottenute le seguenti coppie di valori.

D0(ps)	W1(μm)	W2(μm)
230	3,684031	13,57209
240	2,790038	9,399566
250	2,381626	7,869762
260	2,108948	6,946854
270	1,90117	6,28638
280	1,733453	5,775529
290	1,93489	5,361838
300	1,474081	5,016361
310	1,370576	4,721373
320	1,279761	4,465209
330	1,199305	4,239784
340	1,127462	4,039262
350	1,06288	3,859295
360	1,004507	3,696545
370	1,000002	3,504578


È evidente che aumentando il **ritardo**, gli inverter vengono resi sempre più piccoli, con il primo inverter che praticamente arriva ad avere un **dimensionamento** quasi **minimo** per il ritardo più alto, e la differenza di **sizing** tra secondo e terzo inverter cala in maniera esponenziale.

Tutto ciò avviene perché più si avanza e minore è l'**energia** che devo erogare per garantire un tale **ritardo**: ciò comporta che posso diminuire la **capacità complessiva** e questa cosa la posso fare diminuendo **le larghezze W**, che sono direttamente proporzionali alla **capacità** e quindi all'**energia**.

6 CONFRONTO DEI RISULTATI OTTENUTI

Una volta ottenuto il modello è stato verificato per alcune coppie di punti quanto, a partire da un ritardo D ($W1$, $W2$), il valore di E ($W1$, $W2$) si avvicina a quello della curva teorica. Per ottenere il grafico della curva di ottimo ogni coppia ($W1$, $W2$) ottenuta sul tool di ottimizzazione è stata sostituita nel buffer a tre stadi realizzato su **LTSpice**, dopodiché il circuito viene simulato e si calcola l'energia come per la simulazione montecarlo.

I valori di energia ottenuti dalla simulazione in transitorio vengono interpolati e si ottiene il risultato finale, dove si sovrappongono **curva empirica** e curva ricavata col **modello**.



Nel grafico di **ottimo** sono stati presi anche valori per **230** e **240 ps** per evidenziare come i **modelli** sono stati formulati correttamente e come questi ultimi per il **nodo tecnologico** scelto (**120 nm**) considerino esclusivamente i valori di **energia** compresi nel range di ritardo di interesse. Infine, si evince come i valori della **curva empirica** sono praticamente sopra la **curva di ottimo**, come ci si aspettava da ipotesi iniziale.